

Uydu Görüntüleri ve Yapay Zeka Teknikleriyle Su Yüzey Alan Hesaplaması

1. Proje Konusu ve Seçilme Gerekçesi

1.1 Proje Konusu

Bu projede, **uydu görüntüleri (Sentinel-2 başta olmak üzere)** ve **derin öğrenme tabanlı yapay zeka yöntemleri** kullanılarak durgun su kütlelerinin (göl, baraj, gölet) **su yüzey alanlarının** tespit edilmesi amaçlanmaktadır. Çalışma, su kaynaklarının zamansal değişiminin otomatik, ölçeklenebilir ve düşük maliyetli biçimde izlenmesine odaklanmaktadır.

1.2 Seçilme Gerekçesi

- Son yıllarda iklim değişikliği ve küresel ısınmaya bağlı olarak yaşanan **kuraklık**, tatlı su kaynaklarının sürdürülebilir yönetimini hayati bir mesele haline getirmiştir.
- Türkiye özelinde birçok göl ve barajda **ciddi su seviyesi düşüşleri** gözlemlenmekte, bazı göller tamamen kuruma noktasına gelmektedir.
- Özellikle son dönemde **Bursa gibi büyük şehirlerde yaşanan su sıkıntıları**, tatlı su kaynaklarının etkin izlenmesi ve yönetilmesinin ne kadar kritik olduğunu açıkça göstermektedir.
- Geleneksel yerinde ölçüm yöntemleri hem maliyetli hem de geniş coğrafyalarda sürdürülebilir değildir.
- Uydu görüntüleri sayesinde geniş alanlar düzenli olarak izlenebilmekte, yapay zeka tabanlı yöntemler ile bu verilerden **otomatik, objektif ve tekrarlanabilir** analizler elde edilebilmektedir.

Bu proje, özellikle **tatlı su kaynaklarının yüzey alan değişimlerinin izlenmesi** yoluyla;

- Kuraklık etkilerinin erken tespiti,
- Su yönetimi politikalarının bilimsel verilere dayandırılması,
- Kamu kurumları ve yerel yönetimler için karar destek mekanizmalarının güçlendirilmesi

amaçlarına doğrudan katkı sağlamaktadır.

1.3 Literatürde Yapılan Benzer Çalışmalar

Literatürde su yüzey alanı tespiti için NDWI, MNDWI gibi klasik indeksler yaygın olarak kullanılmıştır. Ancak bu yöntemler:

- Bulut, gölge ve karmaşık zemin koşullarında hataya açıktır.
- Genelleme kabiliyeti sınırlıdır.

Son yıllarda **U-Net**, **U-Net++**, **SegFormer** ve **SAM (Segment Anything Model)** gibi derin öğrenme tabanlı segmentasyon modelleri kullanılarak daha yüksek doğruluk elde edilmiştir. Ayrıca su kalitesi tahmini için regresyon tabanlı makine öğrenmesi ve derin öğrenme yaklaşımları (Random Forest, CNN tabanlı regresyon modelleri) tercih edilmektedir.

1.4 İlgili Alanın Önemi

Bu tür sistemler;

- Erken uyarı mekanizmalarının kurulmasına,
- Su yönetimi politikalarının bilimsel verilere dayandırılmasına,
- Kamu kurumlarının karar destek süreçlerinin iyileştirilmesine katkı sağlamaktadır.

2. Veri Setinin Belirlenmesi

2.1 Kullanılan Uydu Verileri

- **Sentinel-2 MSI** (10–20 m mekânsal çözünürlük)
- Gerekğinde Landsat-8/9 ve MODIS gibi açık erişimli veriler

2.2 Eğitim ve Test Veri Setleri

- **Kaggle – Satellite Images of Water Bodies** veri seti (etiketli su kütlesi maskeleri)
- İdare tarafından sağlanan batimetri ve yerinde ölçüm verileri (referans/ground truth)

2.3 Veri Ön İşleme Adımları

- Bulut maskeleyme
- Bant seçimi ve normalize etme

- Görüntü kırpma (patch extraction)
- Veri artırma (döndürme, ölçekleme, yatay/dikey çevirme)

Bu adımlar, modelin genelleme performansını artırmak amacıyla uygulanmıştır.

3. Uygulanacak Yöntem ve Algoritmaların Seçim Gerekçesi

Bu proje kapsamında problem, **uydu görüntülerinden durgun su kütlelerinin yüzey alanlarının hassas şekilde segmentasyonu** olarak ele alınmıştır. Problem doğası gereği piksel-seviyesinde sınıflandırma gerektirdiğinden, **derin öğrenme tabanlı semantik segmentasyon modelleri** tercih edilmiştir.

3.1 Klasik Yöntemler Yerine Derin Öğrenme Tercihinin Gerekçesi

Literatürde su yüzey alanı tespiti için yaygın olarak kullanılan NDWI, MNDWI gibi spektral indeksler;

- Eşik değerine bağlıdır,
- Bulut, gölge ve karmaşık arka planlarda ciddi hatalar üretir,
- Farklı coğrafi bölgelerde genelleme kabiliyeti düşüktür.

Bu sebeple projede **veriye dayalı öğrenme yapabilen** ve karmaşık mekânsal örüntüleri yakalayabilen derin öğrenme yaklaşımları tercih edilmiştir.

3.2 Kullanılan Modeller ve Mimari Yapılar

Projede aşağıdaki modeller uygulanmış ve karşılaştırılmıştır:

- **ResNet50 + U-Net**
- **ResNet101 + U-Net++**
- **SegFormer-B3**
- **SegFormer-B5**
- **Segment Anything Model (SAM)**

Bu modeller, hem **CNN tabanlı** hem de **Transformer tabanlı** yaklaşımları kapsayacak şekilde seçilmiştir.

3.3 Backbone + Decoder Yaklaşımının Gerekçesi

U-Net ve U-Net++ gibi encoder–decoder mimarilerde, **encoder (backbone)** kısmı görüntüden anlamlı özellikleri çıkarırken, **decoder** kısmı bu özellikleri orijinal çözünürlüğe taşıyarak hassas sınırlar üretir.

- **ResNet50 / ResNet101** gibi derin CNN backbone'ları;
 - Kenar, doku ve lokal örüntüleri güçlü şekilde öğrenir,
 - Önceden ImageNet üzerinde eğitilmiş olmaları sayesinde hızlı yakınsama sağlar.
- **U-Net++**, klasik U-Net'e kıyasla;
 - Çok seviyeli skip-connection yapısı,
 - Daha iyi gradyan akışı,
 - İnce sınırların daha başarılı öğrenilmesi

avantajlarını sunar.

Bu nedenle **ResNet101 + U-Net++** kombinasyonu, daha derin özellik temsili ve daha hassas segmentasyon sağlamaktadır.

3.4 CNN Tabanlı ve Transformer Tabanlı Modellerin Karşılaştırılması

CNN Tabanlı Modeller (ResNet + U-Net / U-Net++)

Avantajları:

- Lokal özellikleri (kenar, şekil) güçlü öğrenme
- Daha düşük hesaplama maliyeti
- Küçük veri setlerinde daha stabil performans

Dezavantajları:

- Uzun menzilli (global) bağlam bilgisini sınırlı öğrenme
- Büyük su kütlelerinde bütüncül algının zayıflaması

Transformer Tabanlı Modeller (SegFormer)

SegFormer mimarisi, **self-attention mekanizması** sayesinde görüntünün tamamındaki ilişkileri aynı anda modelleyebilir.

Avantajları:

- Global bağlam bilgisini güçlü şekilde yakalama
- Farklı ölçeklerdeki su kütlelerine daha iyi genelleme
- Karmaşık arka planlarda daha kararlı sonuçlar

Dezavantajları:

- Daha yüksek GPU ve bellek ihtiyacı
- Eğitim süresinin daha uzun olması

3.5 SegFormer-B3 ve SegFormer-B5 Karşılaştırması

- **SegFormer-B3:** Daha hafif yapı, daha hızlı eğitim
- **SegFormer-B5:** Daha derin Transformer katmanları, daha yüksek doğruluk

Projede elde edilen sonuçlar, **SegFormer-B5'in özellikle büyük ve heterojen su yüzeylerinde daha başarılı olduğunu** göstermiştir.

3.6 SAM (Segment Anything Model) Kullanımının Gerekçesi

SAM modeli, büyük ölçekli ve çeşitli veri setleri üzerinde eğitilmiş **genelleme kabiliyeti yüksek bir temel modeldir.**

Bu projede SAM:

- Referans model olarak,
- Geleneksel segmentasyon modelleri ile kıyaslama amacıyla

kullanılmıştır.

SAM'in güçlü genelleme kabiliyeti bulunmasına rağmen;

- İnce ayar (fine-tuning) yapılmadığında
- Spesifik domain (uydu görüntüleri) için bazen sınır hassasiyetinin düşebildiği

gözlemlenmiştir.

3.7 Model Seçiminde Elde Edilen Genel Bulgular

- CNN + Decoder mimarileri stabil ve güvenilir sonuçlar sunmaktadır.

- Transformer tabanlı SegFormer modelleri, global bağlam gerektiren sahnelerde daha üstündür.
- **Backbone ve decoder'ın birlikte optimize edilmesi**, tek başına kullanılan yapılara kıyasla daha yüksek IoU ve F1-score sağlamıştır.

Bu sonuçlar, literatürdeki güncel çalışmalar ile de uyumludur.

4. Model Eğitimi ve Değerlendirilmesi

4.1 Eğitim Süreci

- Veri bölünmesi: %70 eğitim, %15 doğrulama, %15 test
- Girdi: Sentinel-2 uydu görüntü bantları
- Kayıp fonksiyonu: Dice Loss + Binary Cross Entropy
- Optimizasyon algoritması: Adam

Her model aynı veri seti ve benzer hiperparametreler ile eğitilerek **adil bir karşılaştırma ortamı** oluşturulmuştur.

4.2 Değerlendirme Metrikleri

Bu çalışmada kullanılan modellerin performansı, yalnızca piksel doğruluğunu değil; aynı zamanda **alan örtüşmesi, sınır hassasiyeti, belirsizlik ve model güvenilirliğini** de değerlendirebilmek amacıyla çok sayıda metrik kullanılarak analiz edilmiştir. Kullanılan metrikler ve tercih edilme gerekçeleri aşağıda detaylı olarak açıklanmaktadır:

- **Param (Parametre Sayısı):**

Modelin sahip olduğu toplam öğrenilebilir parametre sayısını ifade eder. Hesaplama maliyeti, bellek kullanımı ve gerçek zamanlı sistemlere entegrasyon açısından önemlidir. Daha az parametreye sahip modeller genellikle daha hızlı ve kaynak dostudur.

- **IoU (Intersection over Union):**

Tahmin edilen su maskesi ile gerçek (ground truth) maske arasındaki örtüşme oranını ölçer. Segmentasyon problemlerinde en yaygın kullanılan metriklerden biridir ve **alan bazlı doğruluğu** doğrudan yansıtır.

- **Dice (F1-Score):**

Özellikle dengesiz sınıf dağılımlarında (su / su olmayan alan) IoU'ya alternatif olarak tercih edilir. Küçük su kütlelerinin değerlendirilmesinde daha hassas sonuçlar sunar.

- **Precision (Kesinlik):**

Modelin su olarak etiketlediği piksellerin ne kadarının gerçekten su olduğunu ölçer. Yanlış pozitiflerin (false positive) azaltılması açısından önemlidir.

- **Recall (Duyarlılık):**

Gerçek su piksellerinin ne kadarının model tarafından doğru şekilde tespit edildiğini ölçer. Özellikle su alanlarının eksik tespit edilmesinin kritik olduğu uygulamalarda önemlidir.

- **Boundary F1-Score:**

Segmentasyon sınırlarının doğruluğunu ölçer. Su–kara geçişlerinin hassas şekilde belirlenmesi gereken uygulamalarda (alan hesaplama gibi) kritik bir metriktir.

- **AP (Average Precision):**

Farklı eşik değerleri altında model performansını değerlendirir. Modelin genel segmentasyon kalitesini ve karar tutarlılığını ölçmek için kullanılır.

- **ECE (Expected Calibration Error):**

Modelin tahmin olasılıklarının gerçek doğruluk ile ne kadar uyumlu olduğunu ölçer. Güvenilirlik ve karar destek sistemlerine entegrasyon açısından önemlidir.

Bu metriklerin birlikte kullanılması sayesinde modeller yalnızca doğruluk açısından değil; **hesaplama maliyeti, sınır hassasiyeti ve güvenilirlik** açısından da kapsamlı şekilde karşılaştırılmıştır.

4.3 Modellerin Karşılaştırmalı Performans Analizi

Model	Loss	Backbone	Param (M)	IoU ↑	Dice ↑	Prec ↑	Rec ↑	Boundary F1 ↑	AP ↑	ECE ↓
ResNet50+UNet	BCE + Dice	UNet	29,803,074	0.7499	0.8571	0.8916	0.8252	0.4818	0.8839	0.0258
ResNet101+UNet++	BCE + Dice	UNet++	56,465,986	0.7594	0.8633	0.8809	0.8463	0.4923	0.9077	0.0190
SegFormer-B3	BCE + Dice	Nvidia/mit-b3	13,677,762	0.7597	0.8634	0.9012	0.8287	0.4894	0.7212	0.0245
SegFormer-B5	Focal + Dice	Nvidia/mit-b5	84,594,113	0.9095	0.9198	0.9653	0.9393	0.7442	0.9693	0.6024

Genel gözlemler:

- ResNet50 + U-Net temel bir referans performans sunmuştur.
- ResNet101 + U-Net++, daha derin backbone sayesinde özellikle sınır bölgelerinde daha yüksek doğruluk sağlamıştır.
- SegFormer-B3, CNN tabanlı modellere kıyasla daha iyi global tutarlılık göstermiştir.
- SegFormer-B5, tüm modeller arasında en yüksek IoU ve F1-score değerlerine ulaşmıştır.

5. Sonuçlar

Bu çalışma kapsamında, uydu görüntülerinden su yüzey alanlarının tespiti problemi ele alınmış ve farklı derin öğrenme tabanlı segmentasyon modelleri karşılaştırmalı olarak analiz edilmiştir. Proje sonucunda elde edilen bulgular aşağıdaki şekilde özetlenebilir:

- **CNN tabanlı encoder-decoder mimarilerinin** (ResNet + U-Net / U-Net++) su yüzeylerinin sınırlarını öğrenmede başarılı ve stabil sonuçlar ürettiği gözlemlenmiştir.
- Backbone derinliğinin artırılması (ResNet50 → ResNet101), özellikle karmaşık sınır bölgelerinde segmentasyon doğruluğunu artırmıştır.
- **U-Net++ mimarisi**, çok seviyeli skip-connection yapısı sayesinde klasik U-Net'e kıyasla daha hassas sonuçlar sunmuştur.
- **Transformer tabanlı SegFormer modelleri**, self-attention mekanizması sayesinde görüntü genelindeki bağlamı daha iyi yakalamış ve büyük ölçekli su kütlelerinde daha tutarlı segmentasyon çıktıları üretmiştir.
- SegFormer-B5 modeli, daha derin Transformer katmanları sayesinde tüm modeller arasında en yüksek IoU ve F1-score değerlerine ulaşarak en başarılı model olmuştur.

- SAM modeli, genel amaçlı ve güçlü bir temel model olmasına rağmen, uydu görüntüleri gibi spesifik bir domain için ince ayar yapılmadığında bazı sınır hassasiyeti problemleri sergilemiştir.

Genel olarak elde edilen sonuçlar, **backbone ve decoder yapılarının birlikte optimize edilmesinin**, tekil veya klasik yöntemlere kıyasla su yüzey alanı segmentasyonunda daha yüksek doğruluk sağladığını göstermektedir.

Bu proje, uydu görüntüleri ve yapay zeka yöntemlerinin tatlı su kaynaklarının izlenmesi açısından etkili ve uygulanabilir bir çözüm sunduğunu ortaya koymuştur.

6. Gelecek Çalışmalar

Bu çalışmada yalnızca su yüzey alanı segmentasyonu ele alınmış olup, geliştirilen altyapı gelecekte daha kapsamlı analizlere olanak sağlamaktadır. İlerleyen çalışmalarda aşağıdaki geliştirmeler planlanmaktadır:

- **Daha fazla göl ve baraj üzerinde testlerin genişletilmesi**, farklı coğrafi bölgelerde model genelleme kabiliyetinin analiz edilmesi
- Uydu spektral bantları kullanılarak **su kalitesi parametrelerinin (klorofil-a, bulanıklık vb.) tahmin edilmesi**
- **Hiperparametre optimizasyonu** (kayıp fonksiyonlarının karşılaştırılması, learning rate tuning, optimizier seçimi)
- Farklı modellerin çıktılarının birleştirildiği **ensemble (birleşik) model yaklaşımlarının** uygulanması
- Elde edilen sonuçların **raporlama ve karar destek sistemlerine entegrasyonu**, kamu kurumları ve yerel yönetimler için görsel panellerin geliştirilmesi

Bu geliştirmeler ile sistemin yalnızca akademik değil, aynı zamanda **operasyonel ve karar destek amaçlı** kullanımı da mümkün hale gelecektir.

Ahmet Nuri Eroğlu - 23120205087